

آمار و احتمال مهندسی

تخمین پارامتر

پاییز ۱۴۰۴

پارامتر چیست؟

○ توزیع‌های احتمال زیر را در نظر بگیرید:

- $Ber(p)$ $\theta = p$
- $Poi(\lambda)$ $\theta = \lambda$
- $U(\alpha, \beta)$ $\theta = (\alpha, \beta)$
- $N(\mu, \sigma^2)$ $\theta = (\mu, \sigma^2)$
- $Beta(a, b)$ $\theta = (a, b)$

○ این توزیع‌ها را مدل‌های پارامتری می‌نامیم.

○ با داشتن مدل، این پارامترها هستند که شکل حقیقی توزیع را مشخص می‌کنند.

○ پارامتر را غالباً با θ نمایش می‌دهیم.

○ توجه کنید که θ می‌تواند اسکالر (مثلاً $\theta = \lambda$) و یا برداری (مثلاً $\theta = (\mu, \sigma^2)$) باشد.




اهمیت تخمین پارامتر

- در دنیای واقعی ما مقدار «صحیح» پارامترهای توزیع احتمالی که برای مدل سازی یک پدیده خاص به کار می رود را نمی دانیم.
- اما می توانیم به مشاهده داده از آن پدیده بپردازیم.
- برای مثال می دانیم شیر آمدن یک سکه توزیع $Ber(p)$ دارد ولی p را نمی دانیم.
- اما می توانیم سکه را چندین بار پرتاب کنیم و تعداد دفعاتی که شیر می آید را مشاهده کنیم.
- باید پارامترهای مدل را از داده مشاهده شده تخمین بزنیم.
- تخمینگر $\hat{\theta}$ یک متغیر تصادفی است که پارامتر θ را تخمین می زند.
- تخمین پارامتر به ما اجازه می دهد:
- درک بهتری از فرایند تولید داده داشته باشیم
- بر مبنای مدل به دست آمده آینده را پیش بینی کنیم
- فرایندهای مختلف را شبیه سازی کنیم



Supervised Learning



میانگین و واریانس نمونه

○ به دنباله متغیرهای تصادفی $(X_1, X_2, \dots, X_n)$ *i.i.d.* که از یک جامعه آماری با توزیع F انتخاب شده باشند، یک **نمونه** از توزیع F می‌گوییم.

○ طبق تعریف، میانگین نمونه برابر است با:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad E[\bar{X}] = \mu, \quad \bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right) \text{ as } n \rightarrow \infty$$

○ واریانس نمونه به صورت زیر تعریف می‌شود:

$$S^2 = \sum_{i=1}^n \frac{(X_i - \bar{X})^2}{n-1}, \quad E[S^2] = \sigma^2$$

○ دیدیم که $\bar{X}$ و S^2 تخمین‌گرهای نااریب از μ و σ^2 هستند.



تخمین نقطه‌ای (Point Estimation)

○ با داشتن نمونه‌ای از متغیر تصادفی X با اندازه n :

$$(X_1, X_2, \dots, X_n)$$

به تخمین پارامتر θ از توزیع این متغیر تصادفی می‌پردازیم:

$$\hat{\theta} = g(X_1, X_2, \dots, X_n)$$

○ $g(X_1, X_2, \dots, X_n)$ تابعی از متغیرهای تصادفی بوده و لذا خود یک متغیر تصادفی است.

○ برای مثال $\hat{\theta} = \bar{X}$ تخمینی از $\theta = \mu$ در توزیع نرمال $X \sim N(\mu, \sigma^2)$ است.

○ تخمین ما بی‌غرض (unbiased) یا ناریب خواهد بود، اگر:

$$E(\hat{\theta}) = \theta$$

○ $(E(\hat{\theta}) - \theta)$ را **بایاس تخمین** می‌نامند.



روش گشتاور (Method of Moments)

○ می‌دانیم گشتاور k -ام متغیر تصادفی X برابر است با:

$$m_k = E(X^k)$$

○ فرض کنید متغیرهای تصادفی X_i نمونه‌ای از جامعه آماری با توزیع X باشند، بنابراین X_i ها i.i.d. هستند و $X_i \sim X$.

○ **گشتاور نمونه** (sample moment) مرتبه k -ام را به صورت زیر تعریف می‌کنیم:

$$\hat{m}_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

○ در واقع $\hat{m}_k$ تخمینی از گشتاور حقیقی m_k است.

○ در روش گشتاور با استفاده از تخمین $\hat{m}_k$ برای گشتاور m_k ، پارامتر θ را تخمین می‌زنیم.



مثال ۱

○ فرض کنید متغیر تصادفی X دارای توزیع نمایی با پارامتر λ باشد:

$$f_X(x; \lambda) = \lambda e^{-\lambda x} : x > 0$$

می دانیم که:

$$m_1 = E(X) = \frac{1}{\lambda}$$

یا:

$$\lambda = \frac{1}{m_1}$$

پس با رویت نمونه‌های X_i داریم:

$$\hat{\lambda} = \frac{1}{\hat{m}_1} = \frac{1}{\frac{1}{n} \sum_{i=1}^n X_i}$$



ادامه مثال ۱

○ فرض کنید نمونه‌هایی که از یک جامعه با توزیع نمایی برداشته‌ایم دارای مقادیر 1, 4, 2, 2, 1, 5, 2, 7 هستند. تخمین پارامتر این توزیع به روش گشتاور چقدر است؟

$$\begin{aligned}\hat{\lambda} &= \frac{1}{\frac{1}{n} \sum_{i=1}^n X_i} \\ &= \frac{1}{\frac{1}{8} (1 + 4 + 2 + 2 + 1 + 5 + 2 + 7)} \\ &= \frac{1}{3}\end{aligned}$$



مثال ۲

○ متغیر تصادفی X دارای توزیع نرمال با میانگین و واریانس نامعلوم است. می‌خواهیم با رویت مقادیر نمونه‌های آن، میانگین و واریانس را تخمین بزنیم. می‌دانیم که:

$$\mu = m_1, \quad \sigma^2 = m_2 - m_1^2$$

پس:

$$\hat{\mu} = \hat{m}_1 = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\hat{\sigma}^2 = \hat{m}_2 - \hat{m}_1^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \left(\frac{1}{n} \sum_{i=1}^n X_i \right)^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \hat{\mu})^2$$



مثال ۳

- توزیع پرتو (Pareto) نقش پررنگی در مدل سازی ترافیک اینترنت ایفا می کند.
- تابع توزیع احتمال پرتو به شکل زیر است:

$$F_X(x) = 1 - \left(\frac{x}{\sigma}\right)^{-\theta} : x > \sigma$$

در صورت نامعلوم بودن σ و θ ، چطور باید آنها را تخمین بزنیم؟

- تا کنون با توزیع پرتو مواجه نشده ایم، پس ابتدا نیاز داریم تا گشتاور مرتبه اول و دوم آن را محاسبه کنیم:

$$f(x) = F'(x) = \frac{\theta}{\sigma} \left(\frac{x}{\sigma}\right)^{-\theta-1} = \theta \sigma^{\theta} x^{-\theta-1} : x > \sigma$$



ادامه مثال ۳

$$\begin{aligned} m_1 = E(X) &= \int_{-\infty}^{+\infty} x f(x) dx = \theta \sigma^\theta \int_{\sigma}^{+\infty} x^{-\theta} dx \\ &= \theta \sigma^\theta \left. \frac{x^{-\theta+1}}{-\theta+1} \right|_{\sigma}^{+\infty} = \frac{\theta \sigma}{\theta-1} : \theta > 1 \end{aligned}$$

$$\begin{aligned} m_2 = E(X^2) &= \int_{-\infty}^{+\infty} x^2 f(x) dx = \theta \sigma^\theta \int_{\sigma}^{+\infty} x^{-\theta+1} dx \\ &= \theta \sigma^\theta \left. \frac{x^{-\theta+2}}{-\theta+2} \right|_{\sigma}^{+\infty} = \frac{\theta \sigma^2}{\theta-2} : \theta > 2 \end{aligned}$$

○ برای $\theta \leq 1$ ، متغیر تصادفی پرتو دارای امید ریاضی نامتناهی، و در صورت $\theta \leq 2$ دارای گشتاور دوم نامتناهی خواهد بود.



ادامه مثال ۳

بنابراین داریم:

$$m_1 = \frac{\theta\sigma}{\theta - 1} , \quad m_2 = \frac{\theta\sigma^2}{\theta - 2}$$

و به دست می آوریم:

$$\hat{\theta} = \sqrt{\frac{\hat{m}_2 - \hat{m}_1^2}{\hat{m}_2}} + 1 \quad \text{and} \quad \hat{\sigma} = \frac{\hat{m}_1(\hat{\theta} - 1)}{\hat{\theta}}$$

- بنابراین با جمع آوری نمونه‌هایی از یک متغیر تصادفی پرتو و محاسبه گشتاور اول و دوم این نمونه‌ها، می‌توان پارامترهای θ و σ را با استفاده از روابط بالا تخمین زد.



تخمین پایدار (Consistent Estimation)

○ تخمینگر $\hat{\theta}$ برای پارامتر θ را پایدار می‌نامیم اگر برای هر $\epsilon > 0$:

$$\lim_{n \rightarrow \infty} P(|\hat{\theta} - \theta| < \epsilon) = 1$$

○ تعبیر: با داشتن داده بیشتر ($n \rightarrow \infty$)، تخمین از مقدار حقیقی فاصله اندکی (ϵ) بگیرد.

○ تعریف بالا در حقیقت تعریف پایداری ضعیف (weak consistency) است.

○ قانون ضعیف اعداد بزرگ: $\lim_{n \rightarrow \infty} P(|\bar{X} - \mu| < \epsilon) \rightarrow 1$

○ $\bar{X}$ همواره تخمین پایداری از μ است.

○ تخمینگر گشتاور به طور کلی یک تخمینگر پایدار است.



روش درست‌نمایی بیشینه (Maximum Likelihood)

○ فرض کنید می‌خواهیم پارامتر θ از توزیع X را تخمین بزنیم.

○ به فرض معلوم بودن θ از X نمونه‌برداری می‌کنیم: $X_i|\theta$

○ می‌خواهیم شانس مشاهده مجموعه داده $(x_1, x_2, \dots, x_n)$ در نمونه $(X_1|\theta, \dots, X_n|\theta)$ را مشخص کنیم.

○ واضح است که این شانس به تابع چگالی احتمال مشترک $f_{X_1 \dots X_n}(x_1, \dots, x_n|\theta)$ است و از آنجایی که X_i ها مستقل از هم هستند:

$$f(x_1, \dots, x_n|\theta) = f(x_1|\theta)f(x_2|\theta) \dots f(x_n|\theta)$$

○ تابع درست‌نمایی (likelihood function) $L(\theta)$ را به صورت زیر تعریف می‌کنیم:

$$L(\theta) = \prod_{i=1}^n f(x_i|\theta)$$



تخمین درست‌نمایی بیشینه

○ توجه کنید که تابع درست‌نمایی $L(\theta)$ به طور شهودی شانس مشاهده مجموعه داده $(x_1, x_2, \dots, x_n)$ را به ازای یک مقدار θ معلوم نشان می‌دهد.

○ تخمینگر درست‌نمایی بیشینه (maximum likelihood estimator) که آن را با $\hat{\theta}_{ML}$ نمایش می‌دهیم، در حقیقت مقداری از پارامتر θ است که تابع $L(\theta)$ را بیشینه می‌کند.

$$\hat{\theta}_{ML} = \arg \max_{\theta} L(\theta)$$

○ به عبارت دیگر به ازای چه مقداری از θ احتمال مشاهده $(x_1, \dots, x_n)$ بیشترین است.



تخمین ML

○ جهت یافتن $\hat{\theta}_{ML}$ باید از تابع $L(\theta)$ نسبت به θ مشتق بگیریم:

$$\frac{\partial}{\partial \theta} \prod_{i=1}^n f(x_i|\theta) = 0 \rightarrow \hat{\theta}_{ML}$$

○ اما از آنجا که $L(\theta)$ یک تابع ضربی است، مشتق آن پیچیده می‌شود.

○ به همین دلیل غالباً از لگاریتم آن که یک تابع جمعی می‌شود استفاده می‌کنیم:

$$LL(\theta) = \ln L(\theta) = \ln \prod_{i=1}^n f(x_i|\theta) = \sum_{i=1}^n \ln f(x_i|\theta)$$

○ تابع $LL(\theta)$ را تابع درست‌نمایی لگاریتمی (log-likelihood function) می‌نامیم.



تخمین ML

○ با توجه به صعودی اکید بودن تابع لگاریتم $\ln(\cdot)$ ، مقداری از θ که تابع $LL(\theta)$ را بیشینه می کند، تابع $L(\theta)$ را هم بیشینه خواهد کرد:

$$\arg \max_{\theta} LL(\theta) = \arg \max_{\theta} L(\theta) = \hat{\theta}_{ML}$$

مثال ۱. برای متغیر تصادفی برنولی $X \sim \text{Ber}(p)$ ، تخمین $\hat{p}_{ML}$ را محاسبه کنید.

تابع چگالی احتمال برنولی به شرط معلوم بودن p برابر است با:

$$f(x_i|p) = p^{x_i}(1-p)^{1-x_i}$$

به فرض داشتن n مشاهده $(x_1, \dots, x_n)$ داریم:



مثال ۱

$$L(p) = \prod_{i=1}^n f(x_i|p) = \prod_{i=1}^n p^{x_i}(1-p)^{1-x_i} = p^{\sum_{i=1}^n x_i} (1-p)^{\sum_{i=1}^n (1-x_i)}$$

$$LL(p) = \left(\sum_{i=1}^n x_i \right) \ln p + \left(\sum_{i=1}^n (1-x_i) \right) \ln(1-p)$$

$$\frac{\partial LL(p)}{\partial p} = \left(\sum_{i=1}^n x_i \right) \left(\frac{1}{p} \right) + \left(\sum_{i=1}^n (1-x_i) \right) \left(-\frac{1}{1-p} \right) = 0$$

$$\Rightarrow \hat{p}_{ML} = \frac{1}{n} \sum_{i=1}^n x_i$$



مثال ۲

○ توزیع ویبول (Weibull) دارای تابع چگالی احتمال زیر است:

$$f_X(x) = cx e^{-c \frac{x^2}{2}}$$

تخمین ML برای پارامتر c را محاسبه نمایید.

$$L(c) = \prod_{i=1}^n (cx_i e^{-c \frac{x_i^2}{2}}) = c^n \left(\prod_{i=1}^n x_i \right) e^{-\frac{c}{2} \sum_{i=1}^n x_i^2}$$

$$\Rightarrow LL(c) = n \ln c + \sum_{i=1}^n \ln x_i - \frac{c}{2} \sum_{i=1}^n x_i^2$$



ادامه مثال ۲

○ پس خواهیم داشت:

$$\frac{\partial LL(c)}{\partial c} = \frac{n}{c} - \frac{1}{2} \sum_{i=1}^n x_i^2 = 0 \Rightarrow \hat{c}_{ML} = \frac{2n}{\sum_{i=1}^n x_i^2}$$

○ اگر مقادیر نمونه مشاهده شده از این توزیع $(1,1,2,1,3,3)$ باشد، تخمین c به روش ML چیست؟

$$\hat{c}_{ML} = \frac{2 \times 6}{1 + 1 + 4 + 1 + 9 + 9} = \frac{12}{25} = 0.48$$

○ بهترین توزیع ویبول که مقادیر فوق را مدل کند عبارت است از:

$$f_X(x) = 0.48x e^{-0.24x^2}$$



مثال ۳

○ تابع چگالی احتمال پواسون به شکل زیر است:

$$P(x) = e^{-\lambda} \frac{\lambda^x}{x!}$$

می‌خواهیم پارامتر λ را به روش ML تخمین بزنیم.

$$L(\lambda) = \prod_{i=1}^n e^{-\lambda} \frac{\lambda^{x_i}}{x_i!} = \frac{(e^{-\lambda})^n \lambda^{\sum_{i=1}^n x_i}}{(\prod_{i=1}^n x_i!)}$$

$$\Rightarrow LL(\lambda) = -n\lambda + \ln \lambda \sum_{i=1}^n x_i - \sum_{i=1}^n \ln(x_i!)$$



ادامه مثال ۳

○ پس خواهیم داشت:

$$\frac{\partial LL(\lambda)}{\partial \lambda} = -n + \frac{1}{\lambda} \sum_{i=1}^n x_i = 0$$

$$\Rightarrow \hat{\lambda}_{ML} = \frac{1}{n} \sum_{i=1}^n x_i$$

○ برای پارامتر λ در متغیر تصادفی پواسون، در صورتی که از روش گشتاور نیز استفاده کنیم به همین تخمین خواهیم رسید.



تخمین ML بیش از یک پارامتر

- فرض کنید می‌خواهیم پارامترهای μ و σ از توزیع نرمال را تخمین بزنیم.
- به این منظور باید از تابع درست‌نمایی یک بار نسبت به μ و بار دیگر نسبت به σ مشتق بگیریم و با حل دستگاه دو معادله و دو مجهول تخمین مناسب را محاسبه کنیم.

$$f(x_i|\mu, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}}$$

$$LL(\mu, \sigma) = \sum_{i=1}^n \ln\left(\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}}\right) = \sum_{i=1}^n \left(-\ln(\sqrt{2\pi}\sigma) - \frac{(x_i - \mu)^2}{2\sigma^2}\right)$$

$$\frac{\partial LL}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \Rightarrow \sum_{i=1}^n x_i - n\mu = 0 \Rightarrow \hat{\mu}_{ML} = \frac{1}{n} \sum_{i=1}^n x_i$$



تخمین ML بیش از یک پارامتر

$$LL(\mu, \sigma) = \sum_{i=1}^n \left(-\ln(\sqrt{2\pi}\sigma) - \frac{(x_i - \mu)^2}{2\sigma^2} \right)$$

$$\frac{\partial LL}{\partial \sigma} = \sum_{i=1}^n \left(-\frac{1}{\sigma} + \frac{(x_i - \mu)^2}{\sigma^3} \right) = 0 \Rightarrow n\sigma^2 = \sum_{i=1}^n (x_i - \mu)^2$$

$$\hat{\sigma}_{ML}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu}_{ML})^2$$



تخمین ML توزیع یکنواخت

○ برای تخمین ML پارامترهای توزیع یکنواخت $U(\alpha, \beta)$ داریم:

$$f(x_i|\alpha, \beta) = \frac{1}{\beta - \alpha} : \alpha < x_i < \beta$$

$$LL(\alpha, \beta) = \ln \left(\frac{1}{\beta - \alpha} \right)^n = -n \ln(\beta - \alpha) : \alpha < x_1, x_2, \dots, x_n < \beta$$

$$\frac{\partial LL}{\partial \alpha} = \frac{n}{\beta - \alpha} = 0 \Rightarrow \text{این معادله جواب ندارد}$$

○ اما از آنجا که شرط $\alpha < x_1, x_2, \dots, x_n < \beta$ باید ارضا شود:

$$\hat{\alpha}_{ML} = \min(x_1, x_2, \dots, x_n) \quad \hat{\beta}_{ML} = \max(x_1, x_2, \dots, x_n)$$



مثال

○ تخمین ML پارامترهای θ_1 و θ_2 را برای توزیع احتمال زیر بیابید:

$$f_X(x; \theta_1, \theta_2) = \theta_1 \theta_2^{\theta_1} x^{-\theta_1-1}, \quad \theta_2 \leq x, \quad \theta_1, \theta_2 > 0$$

○ داریم:

$$\begin{aligned} L(\theta_1, \theta_2) &= \prod_{i=1}^n f(x_i | \theta_1, \theta_2) = \prod_{i=1}^n \theta_1 \theta_2^{\theta_1} x_i^{-\theta_1-1} \\ &= \theta_1^n \theta_2^{n\theta_1} \left(\prod_{i=1}^n x_i \right)^{-(\theta_1+1)} : \theta_2 \leq x_1, x_2, \dots, x_n \\ LL(\theta_1, \theta_2) &= n \ln(\theta_1) + n\theta_1 \ln(\theta_2) - (\theta_1 + 1) \sum_{i=1}^n \ln(x_i) \end{aligned}$$



ادامه مثال

$$\frac{\partial LL}{\partial \theta_1} = \frac{n}{\theta_1} + n \ln(\theta_2) - \sum_{i=1}^n \ln(x_i) = 0 \Rightarrow \hat{\theta}_{1ML} = \frac{n}{\sum_{i=1}^n \ln(x_i) - n \ln \hat{\theta}_{2ML}}$$

$$\frac{\partial LL}{\partial \theta_2} = \frac{n\theta_1}{\theta_2} > 0$$

○ مشتق نسبت به θ_2 همواره مثبت است، بنابراین θ_2 باید تا جای ممکن افزایش یابد، و با توجه به شرط $\theta_2 \leq x_1, x_2, \dots, x_n$ خواهیم داشت:

$$\hat{\theta}_{2ML} = \min\{x_1, x_2, \dots, x_n\}$$

و در نتیجه:

$$\hat{\theta}_{1ML} = \frac{n}{\sum_{i=1}^n \ln(x_i) - n \ln(\min\{x_1, x_2, \dots, x_n\})}$$

